


CLUSTERING: PARTITIONING METHODS (K-MEANS, K-MEDOIDS)

ANGGOTA :

1. A REIGY AZHALIS (241011401343)
2. ALYA GHINA KHOIRUNNISA SURYANINGRAT (241011401332)
3. BILLY NANDA ALFAHRIZI (241011403022)
4. DIVA HANDIKA NOVAL (241011401353)
5. FADJAR ILHAM RIFA'I (241011401336)

Clustering




Clustering

Apa itu Clustering?

Clustering adalah teknik **unsupervised learning** yang digunakan untuk mengelompokkan data yang memiliki kemiripan ke dalam kelompok (cluster). Tujuannya:

- Data dalam cluster yang sama → harus mirip
- Data antar cluster berbeda → harus berbeda sejauh mungkin




Contoh Penerapan

1. Retail / Marketing
 - Analisis pola transaksi pembeli
 - Rekomendasi Buku, Film, Produk baru untuk pelanggan baru
2. Perbankan
 - Deteksi fraud dalam transaksi
 - Pengelompokan nasabah(program loyalitas nasabah)
3. Asuransi
 - Deteksi fraud dalam klaim asuransi
 - Analisa resiko asuransi bagi pelanggan
4. Berita dan penerbitan
 - Kategori berita otomatis
 - Rekomendasi artikel / berita baru

Metode Clustering

1. Partition-Based Clustering
 - K-Means
 - K-Medoid
 - K-Medians
 - Fuzzy c means, dll
2. Hirearchical Clustering
 - Agglomerative(pemusatan)
 - Divisive(penyebaran)
3. Density-Based Clustering
 - DBSCAN, dll




K-Means

Berikut adalah poin-poin utamanya:

- **Partisi Data:** Membagi dataset menjadi (K) kelompok (*cluster*) yang berbeda dan tidak saling tumpang tindih (*non-overlapping*). Setiap titik data hanya boleh menjadi anggota satu kelompok.
- **Kemiripan Intra-cluster:** Berusaha membuat data di dalam satu kelompok seidentik mungkin satu sama lain.
- **Minimalisasi Jarak:** Menempatkan data ke *cluster* tertentu dengan cara meminimalkan jumlah kuadrat jarak antara titik data dan pusat massa kelompoknya (**centroid**).
- **Homogenitas:** Semakin kecil variasi di dalam suatu kelompok, maka data di dalamnya dianggap semakin serupa atau homogen.

Algoritma K-Means



Animasi proses K-Means

an jumlah kluster (nilai k)

asi nilai centroid awal setiap kluster secara acak

jarak setiap titik data dengan setiap centroid

an setiap titik data ke dalam kluster berdasarkan
pusat kluster

setiap kluster, tentukan nilai centroid baru berda
) dari setiap data di dalam kluster

langkah 3-5 sedemikian hingga tidak ada peruk

Klasterisasi Pelanggan


CustID	Age	Income
1	41	19
2	47	100
3	33	57
4	29	19
5	47	253
6	40	81
7	38	56
8	42	64
9	26	18
10	47	115

Tentukan K

- $K = 2$

Tentukan Centroid

- $C1 = 41,19$
- $C2 = 47,100$



Klasterisasi Pelanggan (Iterasi 1)

CustID	Age	Income	Jarak ke C1 (41,19)	Jarak ke C2 (47,100)	Cluster
1	41	19	$\sqrt{(41-41)^2+(19-19)^2} = 0$	$\sqrt{(41-47)^2+(19-100)^2} = 81,22$	1
2	47	100	$\sqrt{(47-41)^2+(100-19)^2} = 81,22$	$\sqrt{(47-47)^2+(100-100)^2} = 0$	2
3	33	57	$\sqrt{(33-41)^2+(57-19)^2} = 38,83$	$\sqrt{(33-47)^2+(57-100)^2} = 45,22$	1
4	29	19	$\sqrt{(29-41)^2+(19-19)^2} = 12,00$	$\sqrt{(29-47)^2+(19-100)^2} = 82,98$	1
5	47	253	$\sqrt{(47-41)^2+(253-19)^2} = 234,08$	$\sqrt{(47-47)^2+(253-100)^2} = 153,00$	2
6	40	81	$\sqrt{(40-41)^2+(81-19)^2} = 62,01$	$\sqrt{(40-47)^2+(81-100)^2} = 20,25$	2
7	38	56	$\sqrt{(38-41)^2+(56-19)^2} = 37,12$	$\sqrt{(38-47)^2+(56-100)^2} = 44,91$	1
8	42	64	$\sqrt{(42-41)^2+(64-19)^2} = 45,01$	$\sqrt{(42-47)^2+(64-100)^2} = 36,35$	2
9	26	18	$\sqrt{(26-41)^2+(18-19)^2} = 15,03$	$\sqrt{(26-47)^2+(18-100)^2} = 84,65$	1
10	47	115	$\sqrt{(47-41)^2+(115-19)^2} = 96,19$	$\sqrt{(47-47)^2+(115-100)^2} = 15,00$	2

Cluster 1

- CustID 1
- CustID 3
- CustID 4
- CustID 7
- CustID 9

Cluster 2

- CustID 2
- CustID 5
- CustID 6
- CustID 8
- CustID 10

Klasterisasi Pelanggan (Iterasi 1)


Cluster 1		
CustID	Age	Income
1	41	19
3	33	57
4	29	19
7	38	56
9	26	18
Centroid Baru	33,4	33,8

Cluster 2		
CustID	Age	Income
2	47	100
5	47	253
6	40	81
8	42	64
10	47	115
Centroid Baru	44,6	122,6

Klasterisasi Pelanggan (Iterasi 1)


Sebelum

Income (Y)



Sesudah

Income (Y)



Klasterisasi Pelanggan (Iterasi 2)

CustID	Age	Income	Jarak ke C1 (33,4 ; 33,8)	Jarak ke C2 (44,6 ; 122,6)	Klaster
1	41	19	16,64	103,66	1
2	47	100	67,58	22,73	2
3	33	57	23,20	66,62	1
4	29	19	15,44	104,77	1
5	47	253	219,62	130,42	2
6	40	81	47,66	41,85	2
7	38	56	22,67	66,93	1
8	42	64	31,40	58,66	1
9	26	18	17,45	106,24	1
10	47	115	82,33	7,97	2

Cluster 1

- CustID 1
- CustID 3
- CustID 4
- CustID 7
- CustID 8
- CustID 9

Cluster 2

- CustID 2
- CustID 5
- CustID 6
- CustID 10

Klasterisasi Pelanggan (Iterasi 2)

Iterasi 1			Iterasi 2			Iterasi 3			Iterasi 4		
CustID	C1	C2	CustID	C1	C2	CustID	C1	C2	CustID	C1	C2
1	0,00	81,22	1	16,64	103,66	1	20,77	118,33	1	26,42	137,13
2	81,22	0,00	2	67,58	22,73	2	62,36	37,29	2	56,31	56,00
3	38,83	45,22	3	23,20	66,62	3	18,26	81,18	3	12,41	99,98
4	12,00	82,98	4	15,44	104,77	4	20,67	119,36	4	26,68	138,18
5	234,08	153,00	5	219,62	130,42	5	214,51	115,76	5	208,46	97,00
6	62,01	20,25	6	47,66	41,85	6	42,48	56,49	6	36,41	75,33
7	37,12	44,91	7	22,67	66,93	7	17,46	81,57	7	11,40	100,40
8	45,01	36,35	8	31,40	58,66	8	26,17	73,32	8	20,19	92,14
9	15,03	84,65	9	17,45	106,24	9	22,63	120,79	9	28,51	139,59
10	96,19	15,00	10	82,33	7,97	10	77,13	22,32	10	71,07	41,00

Iterasi dihentikan karena posisi centroid pada tidak berubah

K-MEDOIDS (PAM)

K-Medoids atau Partitioning Around Medoids (PAM) merupakan pengembangan dari K-Means. Perbedaan utama terletak pada pusat cluster yang digunakan. K-Means menggunakan centroid (rata-rata), sedangkan K-Medoids menggunakan medoid yaitu salah satu data aktual yang memiliki total jarak minimum terhadap data lain dalam cluster. Karena menggunakan data aktual, metode ini lebih tahan terhadap outlier.

Mengapa K-Medoids Dibutuhkan?

K-Medoids dikembangkan sebagai solusi atas kelemahan K-Means yang sensitif terhadap data ekstrem (*outlier*). Pada K-Means, pusat cluster ditentukan berdasarkan nilai rata-rata (centroid), sehingga keberadaan satu atau beberapa data yang sangat berbeda dapat menggeser posisi centroid dan menyebabkan hasil clustering menjadi kurang representatif.

Kelemahan K-Means


- Sensitif terhadap data ekstrem (outlier)
- Centroid dapat bergeser akibat adanya nilai yang terlalu besar atau terlalu kecil
- Hasil clustering dapat menjadi kurang representatif.

Solusi dengan K-Medoids


- Memilih pusat cluster dari data aktual
 - Mengurangi pengaruh outlier
- Menghasilkan cluster yang lebih stabil

Diagram Medoid vs Centroid

Centroid = titik rata-rata seluruh anggota cluster. Medoid = salah satu objek data yang memiliki total jarak terkecil terhadap anggota cluster lainnya. Medoid selalu merupakan data asli sedangkan centroid belum tentu merupakan data asli.




CEROID



MEDOID


Algoritma K-Medoids (PAM)



Pengaruh Outlier


K-Means sangat sensitif terhadap outlier karena centroid dihitung menggunakan rata-rata. Sebaliknya, K-Medoids tetap memilih pusat cluster dari data aktual sehingga outlier tidak terlalu memengaruhi hasil clustering.

K-Means



Outlier (o) menarik centroid (X)

K-Medoids



Outlier (o) tidak terlalu memengaruhi medoid (★)

Perbandingan K-Means dan K-Medoids

K-Means: cepat, sederhana, cocok untuk data besar tetapi sensitif terhadap outlier. K-Medoids: lebih lambat namun lebih robust terhadap outlier dan lebih mudah diinterpretasikan karena pusat cluster merupakan data aktual.

Karakteristik	K-Means	K-Medoids
Pusat Cluster	Centroid	Medoid
Outlier	Sensitif	Lebih Robust
Kecepatan	Cepat	Lebih Lambat
Data	Numerik	Numerik & Kategorikal
Interpretasi	Sedang	Mudah
Kompleksitas	Rendah	Lebih Tinggi

Kapan Menggunakan K-Medoids?

Gunakan K-Medoids ketika dataset mengandung outlier, ketika pusat cluster harus berupa data aktual, atau ketika stabilitas hasil clustering lebih penting daripada kecepatan komputasi.

Dataset Memiliki
Outlier

Pusat Cluster
Data Aktual

Data Numerik &
Kategorikal

Hasil Cluster
Lebih Stabil

Ilustrasi Pengaruh Outlier

Pada K-Means, keberadaan outlier dapat menggeser posisi centroid sehingga hasil clustering menjadi kurang representatif. Sebaliknya, K-Medoids memilih pusat cluster dari data aktual sehingga lebih tahan terhadap pengaruh data ekstrem.

K-Means



X

Ceroid bergeser akibat outlier.

K-Medoids



★

Medoid tetap stabil terhadap outlier.

Kesimpulan

K-Medoids merupakan variasi K-Means yang menggunakan medoid sebagai pusat cluster. Metode ini lebih tahan terhadap outlier, menghasilkan cluster yang lebih stabil, dan cocok digunakan pada data yang mengandung nilai ekstrem.