

LAPORAN PRAKTIKUM

(Data Mining)

Dosen Pengampu: (DR ARYA ADHYAKSA WASKITA S.SI.,M.SI)



Disusun oleh:

Nama : A. Reigy Azhalis
NIM : 241011401343
Kelas : 04TPLP035

**TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PAMULANG
TAHUN 2025/2026**

PERTEMUAN 8

CLUSTERING

A. Landasan Teori

1.1 Analisis Cluster Menggunakan K-Means dan K-Medoids

Analisis cluster yang digunakan dalam penelitian ini adalah metode K-Means dan K-Medoid. Subbab ini menyajikan penelitian terkait sebagai state of the art penelitian. Pembahasan state of the art difokuskan pada algoritma K-Means dan KMedoid yang secara umum yang telah dilakukan untuk menyelesaikan permasalahan clustering. Selain itu, penelitian terkait pada subbab ini juga membahas mengenai klasterisasi K-Means dan K-Medoid yang diimplementasikan secara khusus untuk Covid-19.

Pertama, peneliti mengkaji penelitian komparatif antar algoritma klustering yang dilakukan oleh Rodriguez (Rodriguez et al., 2019). Dua diantara algoritma klasterisasi yang dibandingkan adalah K-Means dan K-Medoid. Mengacu pada penelitiannya, Rodriguez menyatakan bahwa K-Means dan K-Medoid populer digunakan karena keduanya memiliki kemiripan konsep. Diantaranya adalah kemiripan dalam alur pembacaan data, penentuan k kelompok serta kesamaan metode jarak yang digunakan, yaitu (euclidean distance). Sementara itu, terdapat perbedaan mendasar dari kedua algoritma ini. K-Medoid menggunakan objek sebagai perwakilan (medoid) sebagai pusat cluster untuk setiap cluster, sedangkan K-Means menggunakan nilai rata-rata (mean) sebagai pusat cluster. Oleh karena itu, penelitian untuk mengkomparasikan kinerja K-Means dan K-Medoid menjadi research challenge yang menarik dan menantang. Hal ini untuk menguji secara komparatif perihal performa K-Means dan K-Medoid untuk objek klasterisasi tertentu.

Berikutnya, peneliti mengkaji penelitian terdahulu yang secara komparatif telah membandingkan K-Means dengan K-Medoid untuk klasterisasi objek yang berbeda. Hasilnya, terbukti bahwa K-Medoid belum tentu lebih unggul daripada KMeans, pun juga sebaliknya. Penelitian komparatif tentang K-Means dan K-Medoid oleh Qomariyah (Qomariyah & Siregar, 2022) dan Suarna (Suarna et al., 2021) menyatakan bahwa K-Means lebih baik daripada K-Medoid berdasarkan evaluasi DBI. Namun, penelitian Nurhayati (Nurhayati et al., 2019) menyimpulkan bahwa K-Medoid lebih unggul dari K-Means berdasarkan nilai akurasi, waktu eksekusi (execution time) dan kompleksitas waktu (time complexity). Lebih rinci, Qomariyah (Qomariyah & Siregar, 2022) menggunakan perbandingan K-Means dan K-Medoid untuk klasterisasi mahasiswa. Kemudian berdasarkan evaluasi DBI, K-Means menghasilkan nilai 0,781, sedangkan K-Medoid mendapatkan nilai 0,929. Pada evaluasi DBI, nilai yang mendekati 0 adalah nilai yang terbaik. Penelitian berikutnya yang dilakukan oleh Suarna (Suarna et al., 2021) juga membuktikan bahwa K-Means lebih unggul dibandingkan K-Medoid untuk klasterisasi fish cooking menu. Disimpulkan bahwa, K-Means menghasilkan nilai DBI sebesar - 1,535, sedangkan K-Medoid menghasilkan nilai -1,777. Keunggulan K-Medoid atas K-Means dibuktikan oleh Nurhayati (Nurhayati et al., 2019) melalui penelitian menggunakan teknologi big data.

Keunggulan K-Medoid dinyatakan berdasarkan akurasi, waktu eksekusi (execution time) dan kompleksitas waktu (time complexity). K-Medoid memperoleh akurasi lebih baik dengan nilai 63,24%, sedangkan 52,11% untuk akurasi K-Means. Waktu eksekusi (execution time) dari K-Medoid juga menunjukkan performa yang lebih baik. Tercatat bahwa rata-rata kecepatan eksekusi untuk K-Medoid adalah 3,1 ms, sedangkan K-Means sebesar 3,45 ms. Mengacu ke kompleksitas waktu (time complexity), penelitian tersebut menggunakan pembuktian melalui Big O (n^2). Disimpulkan bahwa rata-rata nilai yang dihasilkan oleh K-Medoid adalah 310,157 sedangkan K-Means sebesar 377,886. Ketiga penelitian tersebut membuktikan bahwa studi komparatif antara KMeans dan K-Medoid tetap relevan untuk dilakukan mengingat objek penelitian saat ini berbeda dengan penelitian terdahulu, yakni sebaran Covid-19 di Indonesia.

Penelitian klasterisasi Covid-19 pernah dilakukan oleh Abdullah (Abdullah et al., 2022), yakni melakukan klasterisasi provinsi di Indonesia yang beresiko terpapar Covid-19 berdasarkan data yang terkonfirmasi positif Covid-19, kematian, serta pemulihan. Penelitian tersebut menggunakan algoritma K-Means yang membentuk 3 klaster provinsi.

Kemudian, penelitian yang dilakukan oleh Silvi (Silvi, 2018) membandingkan hasil analisis klaster menggunakan metode titik sentral dan k-means dengan outlier dalam klasterisasi indikator HIV/AIDS di Indonesia. Studi ini menggunakan statistik kesenjangan untuk menentukan jumlah klaster ideal yang mengelompokkan kabupaten menjadi 7 klaster. Hasil penelitian ini menyimpulkan bahwa untuk data dengan outlier, menggunakan centroid link memberikan hasil yang lebih masuk akal dibandingkan dengan metode k. Jumlah kuadrat dalam/jumlah kuadrat antara metode-k adalah 0,12232, sedangkan jumlah kuadrat dalam/jumlah kuadrat dari metode tautan adalah 0,067307. Metode centroid linkage membuat grup lebih homogen, sehingga nilai rasio yang dihasilkan lebih rendah. Hal ini berarti metode centroid linking memiliki kualitas akurasi kelompok yang lebih baik dibandingkan dengan K-Means. Yang kedua adalah studi oleh Supriyadi (Supriyadi et al., 2021) yang meneliti perbandingan algoritma K-Means dan KMedoid untuk mengelompokkan armada truk berdasarkan produktivitas. Dalam penelitian ini, kedua metode clustering digunakan untuk mengklasifikasikan setiap rangkaian kendaraan berdasarkan produktivitas kinerjanya. Penelitian ini membahas tentang perbandingan K-Medoid dan K-Medoid, dilanjutkan dengan uji validasi terhadap hasil cluster yang terbentuk. Indeks Davies-Bouldin yang digunakan sebagai metode evaluasi dalam analisis cluster memberikan nilai validitas 0,67 untuk K-Medium dan 1,78 untuk K-Medoid.

Penelitian ketiga adalah sebagaimana yang dilakukan oleh Fira (Fira et al., 2021). Penelitian tersebut mengelompokkan penyebaran Covid-19 di Indonesia. Tujuan dari penelitian ini adalah untuk mengelompokkan provinsi-provinsi di Indonesia berdasarkan tingkat tinggi dan rendahnya penyakit Covid-19. Penelitian ini juga membandingkan penggunaan dua metode algoritma, yaitu K-Means dan KMedoid. Hasil penelitian menunjukkan bahwa dengan menggunakan metode KMeans, terdapat cluster 1 yang terdiri dari 2 wilayah dan dikategorikan sebagai tinggi, sedangkan

cluster 2 terdiri dari 32 wilayah dan dikategorikan sebagai rendah. Sementara itu, dengan menggunakan algoritma K-Medoid, terdapat cluster 1 yang terdiri dari 4 wilayah dan dikategorikan sebagai tinggi, sedangkan cluster 2 terdiri dari 30 wilayah dan dikategorikan sebagai rendah. Dalam perbandingan ini, diperoleh nilai koefisien silhouette dengan metode K-Means sebesar 0,207, sedangkan nilai koefisien silhouette dengan metode K-Medoid sebesar 0,347. Terakhir, adalah penelitian dari Adha (Adha et al., 2021) yang bertujuan untuk mengelompokkan negara-negara berdasarkan pola kasus Covid-19 di seluruh dunia. Hasil pengelompokan ini dapat digunakan sebagai referensi dan memberikan gambaran mengenai negara-negara dengan tingkat pemulihan yang rendah dapat mempelajari proses pemulihan negara-negara dengan tingkat pemulihan yang tinggi yang berada dalam kelompok yang sama. Hasil penelitian ini menunjukkan bahwa metode K-Means lebih baik daripada metode DBSCAN dalam mengelompokkan kasus Covid-19. Algoritma K-Means memiliki nilai indeks siluet (SI) terbaik sebesar 0.6902, yang tercapai pada eksperimen dengan nilai $k=8$.

1.2 Clustering

Clustering adalah salah satu metode paling terkenal dalam penambangan data. Dalam konteks data mining, clustering mengacu pada proses pengelompokan beberapa data atau objek ke dalam kelompok (cluster) sedemikian rupa sehingga setiap cluster berisi data yang mirip satu sama lain dan berbeda dari objek di cluster lain. Hingga saat ini peneliti masih terus berusaha untuk menyempurnakan model clustering dan menghitung jumlah cluster yang optimal untuk menghasilkan cluster terbaik. Clustering adalah tentang menempatkan objek yang mirip (dekat) ke dalam sebuah cluster dan menjaga jarak antar cluster seluas mungkin.

Suyanto (Suyanto, 2017) menyatakan bahwa clustering adalah proses pengelompokan objek data ke dalam kelompok yang saling mirip, dimana setiap kelompok terdiri dari objek data yang mirip dan berbeda dengan objek data kelompok lain. Clustering adalah tentang menempatkan objek serupa (berjarak dekat) ke dalam kelompok (cluster) sambil menjaga jarak antar kelompok sekecil mungkin. Ada beberapa metode hoarding yang dikembangkan oleh para ahli dan masing-masing metode memiliki karakteristik, kelebihan dan kekurangannya masing-masing. Clustering dapat dibedakan berdasarkan struktur cluster, keanggotaan data cluster, dan kekompakan data cluster. Metode clustering dapat dibagi menjadi dua kelompok berdasarkan strukturnya, yaitu clustering hirarkis dan clustering partisi. Pengelompokan hierarkis mengikuti aturan bahwa kumpulan data dapat dilihat sebagai grup, dan dua atau grup yang lebih kecil dapat digabungkan menjadi satu grup besar, dan seterusnya, hingga semua data dikelompokkan. Metode pengelompokan hierarki adalah satu-satunya metode yang terdapat dalam kelas pengelompokan hierarki. Di sisi lain, metode clustering membagi data menjadi beberapa kelompok yang tidak tumpang tindih, artinya semua data hanya dimiliki oleh satu kelompok. Clustering mengelompokkan data bersama tanpa mempertimbangkan kategori data yang telah ditentukan sebelumnya. Proses ini berbeda dengan proses klasifikasi, dimana kelas data

harus didefinisikan pada awal proses. Oleh karena itu, clustering sering disebut sebagai unclustered data. Cluster memiliki ciri-ciri sebagai berikut: a) Homogenitas yang tinggi antar anggota suatu cluster (dalam cluster). b) Heterogenitas tinggi antar klaster (cluster).

1.3 Algoritma Clustering (Clustering Algorithm)

Clustering adalah salah satu metode dalam Data Mining yang termasuk dalam kategori pembelajaran tanpa pengawasan (unsupervised learning). K-Means adalah salah satu metode non-hirarki dalam clustering data yang bertujuan untuk membagi data ke dalam satu atau lebih klaster. Metode ini melakukan partisi data ke dalam klaster sehingga data dengan karakteristik yang serupa dikelompokkan ke dalam klaster yang sama, sementara data dengan karakteristik yang berbeda dikelompokkan ke klaster lainnya. Tujuan dari data clustering ini adalah untuk meminimalkan fungsi objektif yang ditentukan dalam proses clustering, yang pada umumnya bertujuan untuk mengurangi variasi di dalam sebuah klaster dan memaksimalkan variasi antara klaster. cluster (Dewi & Pramita, 2019).

Pada dasarnya clustering adalah suatu metode pencarian dan pengelompokan data yang memiliki kesamaan karakteristik (similarity) antar data. Clustering adalah salah satu metode penambangan data tanpa pengawasan, yang berarti bahwa metode ini tidak memerlukan pelatihan dan tidak memerlukan tujuan keluaran yang telah ditentukan sebelumnya. Dalam data mining, digunakan dua jenis metode pengelompokan untuk mengelompokkan data, yaitu pengelompokan hierarkis (hierarchical clustering) dan pengelompokan non-hierarkis (nonhierarchical clustering) (Suyanto, 2017).

1.4 K-Means Clustering

K-Means Clustering adalah suatu algoritma pengelompokan iteratif yang melakukan partisi data ke dalam sejumlah cluster yang telah ditetapkan sebelumnya. Algoritma K-Means clustering memiliki sifat yang sederhana untuk diimplementasikan dan dieksekusi, serta cenderung cepat dan adaptif. Algoritma ini umum digunakan dalam praktek, dan secara historis, K-Means clustering menjadi salah satu algoritma yang paling penting dalam bidang data mining (Paembonan & Abduh, 2021).

K-Means Clustering merupakan sebuah metode pengelompokan berdasarkan jarak yang membagi data ke dalam sejumlah cluster. Algoritma ini hanya bekerja dengan atribut numerik. K-Means clustering termasuk dalam kategori partitioning clustering, yang memisahkan data ke dalam daerah-daerah terpisah. Algoritma K-Means terkenal karena kemudahan implementasinya serta kemampuannya dalam mengelompokkan data yang besar dan mengatasi data outlier dengan cepat. Dalam algoritma K-Means, setiap data akan termasuk dalam satu cluster tertentu pada tahap awal, namun pada tahap-tahap berikutnya, data tersebut dapat pindah ke cluster lain jika terdapat perubahan yang lebih sesuai (Abdullah et al., 2022).

Pada tahap awal K-Means clustering, beberapa komponen dari populasi data dipilih secara acak sebagai pusat cluster awal. Setelah itu, algoritma K-Means menguji setiap komponen data dalam populasi dan menentukan ke pusat cluster mana komponen

tersebut akan dikelompokkan, berdasarkan jarak minimum antara komponen tersebut dengan setiap pusat cluster. Posisi pusat cluster kemudian dihitung ulang berdasarkan komponen-komponen data yang telah dikelompokkan, dan proses ini berulang sampai semua komponen data tergolong dalam cluster-cluster yang sesuai. Pada akhirnya, akan terbentuk cluster-cluster baru yang telah didefinisikan.

1.5 Langkah Clustering K-Means

Berdasarkan Rahayu (Rahayu et al., 2019), proses clustering dengan menggunakan algoritma K-Means clustering memiliki tahapan antara lain:

1. Tahap Inisialisasi: Menentukan jumlah cluster yang diinginkan (K) dan tingkat perbedaan (jarak) yang diinginkan. Jika diperlukan, menetapkan ambang batas perubahan fungsi objektif dan ambang batas perubahan posisi centroid.
2. Memilih K titik data acak dari set data X sebagai centroid awal.
3. Mengelompokkan semua data ke dalam centroid terdekat berdasarkan metrik jarak yang telah ditentukan (memperbarui ID setiap data).
4. Menghitung kembali posisi centroid (C) berdasarkan data yang termasuk dalam setiap cluster.
5. Mengulangi langkah c dan d sampai kondisi konvergensi tercapai, yaitu: (a) perubahan fungsi objektif sudah di bawah ambang batas yang diinginkan, atau (b) tidak ada data yang berpindah ke cluster lain, atau (c) perubahan posisi centroid sudah di bawah ambang batas yang ditetapkan.

1.6 K-Medoid Clustering

K-Medoids clustering, juga dikenal sebagai Partitioning Around Medoids (PAM), merupakan variasi dari metode K-Means. Metode ini berbeda dalam penggunaan medoids sebagai representasi pusat cluster daripada menggunakan mean dari setiap cluster. Tujuan penggunaan medoids adalah untuk mengurangi sensitivitas partisi terhadap nilai ekstrem yang terdapat dalam dataset. (Andini & Arifin, 2020).

Menurut Kauffman dan Rousseeuw dalam Nadliyah (Nadliyah et al., 2019), algoritma yang digunakan dalam clustering K-Medoids didasarkan pada pencarian objek yang mewakili k (sejumlah cluster) objek dalam data. Objek yang mewakili suatu cluster atau k disebut medoid. Setelah menemukan sekumpulan objek untuk bertindak sebagai medoid, langkah selanjutnya adalah membuat cluster dengan menugaskan setiap objek data (non-medoid) ke medoid terdekat.

Algoritma K-Medoids bertujuan untuk mengatasi kelemahan clustering K-Medoids yang sensitif terhadap outlier. Dalam K-Means, elemen dengan nilai besar dapat menyimpang secara signifikan dari distribusi data, sehingga memengaruhi hasil pengelompokan secara keseluruhan. Namun, dengan algoritma K-Medoids, pusat klaster asli masih dipilih secara acak, seperti halnya dengan K-means. Proses iteratif selanjutnya dalam algoritma K-Medoids adalah secara terus-menerus mengganti objek yang berada di tengah cluster dengan objek lain. Tujuan dari iterasi ini adalah untuk terus meningkatkan kualitas cluster yang dihasilkan dengan mengukur kualitas tersebut

menggunakan fungsi rata-rata perbedaan (jarak) antar objek di pusat cluster. Namun, perlu diingat bahwa karena objek pusat cluster terus berubah, stabilitas hasil cluster mungkin tidak tercapai dan kualitas clustering mungkin menjadi tidak stabil. Kualitas ini dievaluasi menggunakan fungsi perbedaan rata-rata (jarak) antara objek dan pusat cluster (Sindi et al., 2020).

Menurut Septiani (Septiani et al., 2022), Berikut adalah tahapan K-Medoids clustering:

1. Memilih secara acak K objek dari total N objek sebagai objek representatif (medoids).
2. Menghitung jarak antara setiap objek dengan masing-masing medoids.
3. Menetapkan setiap objek ke cluster yang sesuai dengan medoids terdekat, dan menghitung fungsi objektif yang merupakan jumlah ketidakmiripan (dissimilarity) antara setiap objek dengan medoids terdekat (yang memiliki jarak minimum).
4. Memilih secara acak objek yang bukan medoids (non-medoids).
5. Menghitung jarak antara setiap objek dengan masing-masing non-medoids.
6. Menetapkan setiap objek ke cluster yang memiliki jumlah ketidakmiripan minimum antara objek tersebut dengan non-medoids terdekat.
7. Menghitung selisih (perbedaan) fungsi objektif sebelum dan sesudah perubahan.
8. Jika pertukaran objek representatif (medoids) dengan non-medoids mengurangi fungsi objektif, maka melakukan penggantian tersebut.
9. Mengulangi langkah d-h sampai tidak ada perubahan pada objek representatif.
10. Analisis dianggap selesai jika tidak ada perubahan pada objek representatif (medoids).

Tahapan ini menjelaskan bagaimana K-Medoids clustering dilakukan untuk membangun cluster dengan objek representatif yang lebih stabil dan tahan terhadap outlier.

1.7 Davies Bouldin Indeks

Davies Bouldin Index adalah salah satu metode evaluasi clustering yang digunakan untuk mengevaluasi dan mengukur seberapa baik clustering yang telah dilakukan melalui metric kohesi dan metric separasi, Evaluasi Clustering terbagi menjadi dua yaitu, Internal Evaluation dan External evaluation, untuk internal mengevaluasi menggunakan data yang ada, contoh metode nya antara lain, davies bouldin index, dunn index, sedangkan external evaluation menggunakan informasi terdahulu mengenai data contoh metode nya antara lain Rand Measure, fmeasure, jaccard index, pada penelitian ini peneliti akan menggunakan DaviesBouldin Index (DBI), DBI merupakan salah satu metode validasi cluster untuk evaluasi kuantitatif dari hasil clustering. Metode ini ditemukan pertama kali oleh David L. Davies dan Donald. Pada tahun 1979, Pengukuran ini bertujuan memaksimalkan jarak intercluster antara satu

cluster dengan cluster yang lain. Dalam penelitian ini DBI akan digunakan untuk mendeteksi outlier pada masing masing cluster yang terbentuk (Singh et al., 2020)

B. Laporan Praktikum

Tugas yang saya buat adalah kode program python yang dimana membandingkan metode K-Means dan K-Medoids menggunakan elbow dan silhouette untuk menentukan jumlah cluster yang cocok


2.1 Membuat dataset dan normalisasi data

```
X, y_true = make_blobs(  
    n_samples=300,  
    centers=4,  
    cluster_std=0.6,  
    random_state=42  
)  
  
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```


2.2 Inertia

Inertia: 6.415444329452049 Nilai 6.41 menunjukkan cluster cukup padat.

2.3 Menentukan jumlah cluster menggunakan elbow dan silhouette



Garis menekuk kebawah memperlihatkan jumlah cluster = 3 cocok digunakan, untuk jumlah cluster > 3 secara tidak signifikan menekuk kebawah



Untuk score jumlah cluster yang tinggi adalah $K = 4$

Optimal k (Elbow): 3



Optimal k (Silhouette): 4

Best Score: 0.879591338894901

2.4 Menambah Outlier

```
outliers = np.array([
    [8,8],
    [9,9],
    [-3,8],
    [5,-4]
])
```

2.5 Perbandingan K-Means dan K-Medoids



K-Means Inertia : 65.70304207986385

K-Medoids Inertia : 116.08899096010306

C. Kesimpulan

Metode	Inertia	Tahan Outlier	Pusat Cluster
K-Means	65.70	Kurang	Centroid (rata-rata)
K-Medoids	116.09	Lebih baik	Medoid (data asli)

Dari hasil ini:

- Silhouette Score menunjukkan jumlah cluster terbaik adalah 4, sesuai dengan data yang dibuat.
- K-Means menghasilkan cluster lebih kompak (inertia kecil).
- K-Medoids menghasilkan inertia lebih besar tetapi lebih robust terhadap outlier.
- Kedua algoritma memiliki tujuan yang sama, yaitu mengelompokkan data, tetapi menggunakan pusat cluster yang berbeda.